

ENSAE Pierre Ndiaye — ISEP 2ème année
TP1 R : Maîtrise des types de données et construction de data frame

M/H/Di@ll0

April 2026

Consignes générales

- Travail individuel.
- Le rendu doit obligatoirement contenir :
 - le fichier `.Rmd`
 - le fichier `.pdf` généré à partir du `.Rmd`
- **Seul un lien GitHub sera accepté**, et ce lien devra contenir l'ensemble du dossier de travail.
- Aucune capture d'écran ne remplace le code.
- Les réponses doivent être rédigées, justifiées et accompagnées du code nécessaire.

Exercice 1 — Typage implicite, coercion et ambiguïtés

On considère les objets suivants définis dans un script R :

```
x <- c(1, 2, 3)
y <- c(TRUE, FALSE, TRUE)
z <- c("4", "5", "6")
w <- list(1, "2", TRUE)
```

Travail demandé

1. Déterminer, **sans exécuter le code**, le type et le mode de chaque objet.
2. Analyser précisément le résultat des expressions suivantes :
 - `x + y`
 - `x + z`
 - `as.numeric(z) + x`
 - `unlist(w) + x`
3. Identifier tous les cas dans lesquels R effectue une coercion implicite.
4. Préciser, pour chaque cas, le type cible et la logique de conversion mobilisée.
5. Discuter rigoureusement les conséquences de l'instruction suivante :

```
as.numeric(c("10", "A", "20"))
```

6. Proposer une méthode robuste permettant de détecter automatiquement les conversions problématiques dans un vecteur.

Exercice 2 — Structures hétérogènes et propagation des types

On considère la construction suivante :

```
A <- c(1, 2, 3)
B <- c("a", "b", "c")
C <- c(TRUE, FALSE, TRUE)
D <- data.frame(A, B, C)
```

Travail demandé

1. Déterminer le type de chaque colonne de D.
2. Expliquer précisément pourquoi R accepte cette structure malgré l'hétérogénéité initiale.
3. Comparer le comportement de l'objet D avec celui obtenu après l'instruction suivante :

```
as.matrix(D)
```

4. Déterminer le type final de la matrice obtenue et justifier formellement la réponse.
5. Montrer en quoi cette transformation peut entraîner une perte d'information statistique dans un contexte d'analyse de données.
6. Proposer une stratégie permettant de préserver les types tout en rendant possibles certaines opérations de nature matricielle.

Exercice 3 — Facteurs, encodage et biais d'interprétation

On considère le vecteur suivant :

```
niveau <- c("faible", "moyen", "élevé", "moyen", "faible")
```

Travail demandé

1. Transformer `niveau` en facteur ordonné avec une hiérarchie pertinente.
2. Déterminer les valeurs numériques internes associées aux modalités.
3. Expliquer pourquoi l'instruction suivante peut être dangereuse dans une analyse :

```
as.numeric(niveau)
```

4. Proposer une méthode correcte pour obtenir une représentation numérique cohérente.
5. On définit le vecteur suivant :

```
revenu <- c(100, 200, 300, 250, 150)
```

Discuter la validité statistique de l'expression :

```
mean(revenu[niveau == "élevé"])
```

6. Identifier un biais potentiel si les niveaux du facteur sont mal ordonnés.

TP 4 — Construction structurée d'un data frame

On dispose des informations suivantes sur une cohorte d'étudiants :

- identifiant unique
- sexe
- filière (ISEP, ISE, AS)
- moyennes semestrielles S1 et S2
- statut de boursier
- région d'origine, avec certaines valeurs manquantes

Travail demandé

1. Construire un `data.frame` cohérent en respectant :
 - le typage explicite des variables ;
 - la **conversion** appropriée des variables qualitatives ;
 - la gestion correcte des valeurs manquantes.
2. Créer une variable `moyenne_annuelle` en tenant compte des cas incomplets.
3. Créer une variable qualitative prenant la modalité :
 - "Admis" si la moyenne annuelle est supérieure ou égale à 12 ;
 - "Ajourné" sinon.
4. Examiner s'il est pertinent de transformer la variable `filiere` en facteur ordonné, puis justifier rigoureusement le choix retenu.
5. Vérifier la structure complète de l'objet et commenter :
 - les types ;
 - la cohérence ;
 - les éventuelles anomalies.
6. Implémenter un contrôle automatique permettant de détecter :
 - les incohérences de type ;
 - les valeurs aberrantes ;
 - les valeurs manquantes critiques.
7. Discuter les implications de ces choix de typage pour :
 - une régression linéaire ;
 - une analyse factorielle.

Modalités de rendu

Le dépôt GitHub remis doit contenir au minimum :

- le fichier source `.Rmd`
- le fichier `.pdf` compilé
- tout fichier annexe utile à la reproduction du travail

Tout rendu ne respectant pas cette consigne sera considéré comme non conforme.